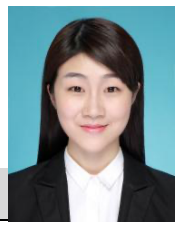

# 张安琦

邮箱：13598102804@163.com | 电话/微信：13598102804 | 政治面貌：中共党员

## 研究方向

**博士期间的研究高度聚焦于大语言模型等人工智能模型的效率、安全与可解释性**，具体可凝练为三大核心板块：**①是大语言模型(LLM)与推理模型(LRM)行为检测与优化**，通过提出大模型自验证探测方法与提前退出策略显著提升模型应用效率、优化推理成本，同时关注大模型预训练数据隐私安全；**②是模型可解释性与鲁棒性**，提出基于深度学习可解释性和因果推理的新型量化指标与算法，对模型预测进行精准诊断、归因和解释，增强系统可信性和故障排查能力；**③是投毒攻击与防御诊断**，设计针对图神经网络的定向数据投毒攻击算法及其防御策略。系统地研究并构建可信、高效的 AI 模型，在国际顶级会议 ICML、COLM 上发表论文。此外，曾致力于**深度学习的跨领域应用**，例如将深度学习技术落地于操作系统领域，实现高精度深度学习建模，通过定制化 DNN 模型预测存储性能。

## 教育背景

**纽约大学（QS-55），**计算机科学，博士(GPA:3.982/4.0) 美国，纽约|2019.09-2025.08

**芝加哥大学（QS-13），**计算机科学，理学硕士(GPA:3.5/4.0) 美国，芝加哥|2017.09-2018.12

**北京邮电大学（211），**电子商务及法律，学士(GPA:3.89/4.0)(联合培养中英院校双授课) 中国，北京|2013.09-2017.06

**伦敦玛丽女王大学，**电子商务及法律，荣誉理(工)学学士(GPA:3.6/4.0) 英国，伦敦|2013.09-2017.06

## 实习/科研实践经历

**纽约大学，柯朗数学科学研究所，推理模型(LRMs)自验证研究项目，**研究助理 美国，纽约|2025.01-2025.07

- **项目介绍：**探索推理模型（如 DeepSeek-R1）能否在复杂推理过程中评估中间答案正确性，解决模型“过度思考”（在得出正确答案后仍生成冗余内容）的问题，以提高推理效率和性能；
- **技术实现：**①编写代码运行大语言推理模型（LRMs），使用提示工程（prompt）引导模型（如 DeepSeek-R1,QwQ-32B,Google Gemini-2）执行各种推理任务，深入研究推理模型的思维链（Chain-of-Thought）和独特的搜索式推理行为；②利用隐藏状态探测技术，揭示模型内部编码的答案正确性信息，构建基于隐状态的高度校准的验证器，量化模型对自身推理结果的置信度；③设计并实现基于置信度的提前退出策略，显著降低推理成本（24%Token 消耗减少），保持推理性能不变；
- **项目成果：**显著降低推理成本，揭示推理模型未充分利用的自我验证潜力，即推理模型隐式编码的信息可自验证/评估其自身生成的中间答案正确性，以第一作者发表论文被大语言模型领域国际新星顶会 COLM 2025 录用；

**纽约大学，柯朗数学科学研究所，大语言模型预训练数据自适应检测项目，**研究助理 美国，纽约|2024.01-2024.06

- **研究介绍：**提出一种自适应的预训练数据检测方法，用于判断文本输入是否包含在大语言模型（LLM）的训练集中；
- **技术实现：**①深入研究 LLM 部署中预训练数据引发的隐私泄露、版权侵权和安全风险等核心问题，掌握预训练数据检测/溯源技术；②设计基于香农熵的 SURP 算法，定位“意外词源”（预测置信度高但结果错误），并基于预测概率计算检测分数以区分已见/未见数据，无需访问原始训练数据或训练参考模型；③构建新的评测框架 Dolma-Book，验证方法在多个 LLM 基准测试中的有效性，相比现有成员推断攻击（MIAs）提升 29.5%；
- **项目成果：**为大语言模型的隐私保护和安全部署提供了新的解决方案；以第一作者发表论文被 EI 收录；

**纽约大学，柯朗数学科学研究所，图神经网络定向投毒攻击和防御诊断项目，**研究助理 美国，纽约|2023.01-2024.04

- **项目介绍：**开发针对图神经网络（GNNs）节点分类任务的实用化定向投毒攻击方法，并设计相应的防御诊断策略；
- **技术实现：**①深入研究 GNN 面临的目标性投毒攻击威胁模型及其危害，设计远端节点的特定攻击，突破传统局限性；②提出两种基于优化的算法 MetaLDT 和 MimicLDT，通过注入长距离节点实现定向投毒，其中 MetaLDT 攻击成功率更高，MimicLDT 可扩展到大规模图（如 ArXiv，20 万+节点）；③设计基于 AME 框架的防御策略，适配至图领域，实现子图级数据投毒检测，用于诊断隐蔽攻击，提升模型鲁棒性；
- **项目成果：**以第一作者发表论文作为预印本放在 ArXiv 上；

**纽约大学，柯朗数学科学研究所，机器学习/深度学习可解释性(AME)项目，**研究助理 美国，纽约|2019.12-2022.07

- **项目介绍：**项目与微软纽约研究院合作完成，研究深度学习可解释性问题，提出新的量化指标 AME（平均边际效应），用于衡量每个训练数据点对模型预测的贡献度；
- **技术实现：**①深究量化训练数据对模型的贡献，明晰 Shapley 值等方法及计算成本高的局限；②提出基于因果推断与随机实验的训练数据贡献度量化算法，定义 AME 并实现其高效估计；③通过随机采样训练子集训练多个子模型，利用 LASSO 回归联合解算各数据点的 AME，将所需模型训练降低至 O(klogN)，并结合 Knockoffs 方法实现高贡献数据的可控筛选，显著优于现有 Shapley 值估计方法；
- **应用前景：**可应用于毒化/后门攻击检测，增强模型安全性，同时为黑盒模型提供高效的数据归因方法，提升模型透明度；
- **项目成果：**以（共同）第一作者发表论文被机器学习/人工智能方向的 CCF-A 类国际顶级会议 ICML 2022 录用；

**微软研究院，**纽约实验室，研究实习生（由微软研究院首席研究员 Siddhartha Sen 指导） 美国，纽约|2021.06-2021.08

- **深度学习模型数据移除：**基于训练数据贡献诊断框架（AME framework），设计集成方法实现高效精确的数据移除，以满足用户隐私协议需求；独立完成实验验证，相关成果在 MSR NYC-lab 全体科研会议上汇报，获广泛好评；

- **对抗检测生成式攻击设计：**构建类 GAN 的多判别器框架，用于规避特定数据投毒检测器，成功针对机器学习图像分类器（合成与优化任务）构造数据投毒攻击，完成模型搭建与实验验证；

**芝加哥大学，UCARE 实验室，面向深度学习操作系统的存储感知 DNN 项目，**研究助理　　美国，芝加哥|2017.09-2019.02

- **项目介绍：**设计定制化的深度神经网络（DNN），实现对通用黑盒 SSD 性能的预测，支持高性能存储系统的应用；
- **技术实现：**①设计并实现定制化的 DNN，用于预测通用黑盒 SSD 的性能，支持高性能存储系统；②利用 Keras 和 TensorFlow 构建适用于 RAID 风格 FTL 的神经网络拓扑模型，实现对 SSD 延迟的高精度预测（准确率大于 99.5%）；③在工业级 SSD 采集的真实 IO 负载数据上验证 DNN 模型的预测性能，覆盖只读与读写混合场景；
- **项目成果：**以第二作者发表论文被计算机系统领域 CCF-A 类国际顶级会议 OSDI 2018 录用；

**北京大学，信息科学中心，社交网络信息扩散检测，**研究实习生　　中国，北京|2016.09-2016.09

- **数据分析：**从 Twitter、微博采集非结构化数据，清洗后用于情感分析和信息检索，为贝叶斯分类器和人工神经网络（ANN）等分析方法准备数据；

**新浪集团，**核心技术部，前端开发实习生　　中国，北京|2016.02-2016.03

- **前端开发：**参与新浪网站前端功能开发，完成新闻网站页面布局改版，优化用户体验，提升单位时间内的用户浏览量；
- **数据挖掘与后端支持：**基于微博平台用户数据，开展数据挖掘与用户行为预测算法开发以预判目标客户行为；同时参与后端数据库运维，保障新项目稳定运行，深入了解工业界项目运营维护流程；

**北京邮电大学，网络与交换技术全国重点实验室，未来无线通信网络自优化技术研究与应用**　中国，北京|2015.05-2016.05

- 提出并应用自组织映射（SOM）神经网络算法准确定位干扰故障接入点（AP），构建软件仿真平台，实现网络负载动态变化下的干扰自优化；开发用户端手机 APP，使用户首次接入网络时能智能连接至当前区域最优无线网络；

**北京邮电大学，电子工程学院，未来通信自组织网络项目，**研究助理　　中国，北京|2015.02-2015.06

- 参与国家自然科学基金委重点项目"未来通信自组织网络"；负责自组织无线网络理论研究，应用于应急通信场景下的 5G 网络设计和智能分配单元（IDU）硬件的开发与实现；

## 论文

- 博士毕业论文《Diagnosing AI Misbehavior: Why Do Models Fail?》(2025，专著)；
- 《Reasoning Models Know When They're Right: Probing Hidden States for Self-Verification》(COLM 2025，第一作者)；
- 《Adaptive Pre-training Data Detection for Large Language Models via Surprising Tokens》(EI, 2024，第一作者)；
- 《Practical Targeted Poisoning Attacks on Graph Neural Networks using Long-distance Node Injection》(ArXiv, 2024，第一作者)；
- 《Measuring the Effect of Training Data on Deep Learning Predictions via Randomized Experiments》(ICML 2022，共同第一作者)；
- 《Machine Learning for Operating Systems: A Case of Using Deep Neural Network for OS-Level I/O Latency Prediction》(OSDI 2018，第二作者)；
- 《WLAN Interference Self-Optimization using SOM Neural Networks》(SCI Journal, 2016，第三作者)；
- 《Optimization Design and Application of Intelligent Parking Lot in Smart City》(IEEE UV 2016，第二作者)；

## 荣誉/奖项

- （国际级）美国大学生数学建模竞赛，二等奖　　2015
- （国家级）下一代互联网技术创新大赛，全国创意组二等奖/华北赛区创意组一等奖　　2015
- 荣获 4 次市级/校级"三好学生"、3 次校级奖学金(top 3%)、1 次国家奖学金（国奖，top 1%）　　2013-2017

## 活动经历

- 北京邮电大学，国际学院 2013 级学生党支部，党支部宣传委员　　中国，北京|2013.09-2017.06
- 北京邮电大学，国际学院学生会，公关部干事　　中国，北京|2013.09-2015.06
- 北京邮电大学，广播台，副台长　　中国，北京|2013.09-2016.06

## 技能＆语言

技能：

- ✓ **人工智能技能：**精通 vLLM、HuggingFace 框架，熟练掌握 DeepSeek、ChatGPT、通义千问、Gemini 等开源模型/闭源 API 集成工具；深入实践 RAG（BM25/Contriever, LlamaIndex），熟悉 AI Agent（LangChain）开发；
- ✓ **编程语言：**Python（PyTorch/TensorFlow）、Java、LaTeX、HTML、MySQL、C++、C、R、Mathematica 等；
- ✓ **云与开发工具：**AWS/Google Cloud/Azure、Git、Hadoop、Spark 等；

语言：普通话（母语）、英语（可作为工作语言/CET6/TOEFL/GRE: 154+167+3.5）；

爱好：舞蹈（8 级）、演讲主持（省级一等奖）、播音、普拉提。